



IEEE
**Computational
Intelligence**
Society



Universidade de Brasília
IEEE Student Branch

Trainee CIS 2026

Período 4- MLOps

Conteúdos

1. Introdução ao Ciclo de Vida de ML
 - a. [Machine Learning Engineering for Production \(MLOps\)](#) - Visão geral do ciclo de vida de ML
 - b. [The Machine Learning Lifecycle](#) - Artigo introdutório descrevendo as fases desde a concepção até a produção
2. Gerenciamento de Experimentos e Dados
 - a. [MLflow Tracking Quickstart](#) - Guia oficial abordando o rastreamento de experimentos usando MLflow
3. Isolamento de ambientes e reprodutibilidade
 - a. [Docker for Beginners \(TechWorld with Nana\)](#) - Curso em vídeo cobrindo os fundamentos essenciais de contêineres
4. Data Drift (Desvio de dados) e Concept Drift (Desvio de conceito)
 - a. [What is data drift in ML, and how to detect and handle it](#) - Artigo explicando o conceito de desvio de dados em Machine Learning e estratégias práticas para detecção e tratamento
5. Serviço e Deploy (Model Serving)
 - a. [Tutorial Introdutório FASTAPI \(DataCamp\)](#) - Guia passo a passo focado na criação rápida de APIs para servir modelos de Machine Learning
 - b. [Visão geral de Deploy \(GeeksforGeeks\)](#) - Artigo que apresenta os conceitos fundamentais e as principais abordagens para colocar modelos em produção
6. Pipelines de retreinamento automático
 - a. [Continuous Training in ML \(Google Cloud\)](#) - Arquitetura de referência descrevendo o funcionamento de pipelines de retreinamento automático
 - b. [Implementação de fluxos de CI/CD em MLOps](#) - Construção prática de workflows de integração e entrega contínuas voltados para operações de ML
 - c. [Automação de CI/CD para Machine Learning](#) - Artigo detalhando a aplicação dos conceitos de engenharia de software (CI/CD) para automação dos ciclos de vida de modelos.
 - d. [Monitoramento e Continuous Training no GCP](#) - Tutorial avançado sobre como implementar o monitoramento de modelos e o treinamento contínuo utilizando as ferramentas do Google Cloud Platform

Atividade Prática- Telco Customer Churn

[O dataset](#) representa uma empresa fictícia de telecomunicações que forneceu serviços de telefone e internet a 7.043 clientes na Califórnia no terceiro trimestre. Cada linha representa um cliente, e cada coluna contém um atributo descritivo.

O seu papel é criar um pipeline de treinamento, monitoramento e deploy dos modelos pré-treinados. O uso de qualquer ferramenta do seu interesse é permitido, porém como sugestão, use as ferramentas mlflow, FastAPI e Docker.

Atividades Obrigatórias

- Implementar o rastreamento de experimentos com MLflow (src/[model.py](#))
 - Completar a função `train_all_models` e criar um loop de treinamento na função `main`

Atividades Opcionais

- Criar a API de inferência com FastAPI (src/[api.py](#))
 - Este arquivo ainda não existe e é um dos principais TODOs. A implementação deve contemplar:
 - Endpoint POST `/predict` que recebe um JSON com os campos do cliente (os mesmos do dataset, exceto `customerID` e `Churn`).
 - Carregamento do `best_model.pkl` e do `scaler.pkl` na inicialização da aplicação (usando `lifespan` do FastAPI).
 - Aplicação das mesmas transformações do `preprocess_data` na entrada — replicando `encoding` e `escalonamento` — utilizando as colunas salvas em `columns.pkl` para garantir alinhamento de features.
- Criar a interface gráfica com Streamlit (src/[app.py](#))
 - Complementar à API, a interface Streamlit permitirá interação visual com o modelo:
 - Formulário com inputs para cada feature do cliente (sliders para `tenure` e `MonthlyCharges`, selects para `Contract`, `InternetService`, etc.).
 - Botão de predição que chama a API FastAPI via `requests.post()` ou executa a inferência diretamente, gerando um gráfico.

Faça um fork do [projeto](#) submeta o link pelo [formulário](#)